

한모코 (HMC) 학습일지


이름	서영재	학번	20195178
날짜	2022.11.03.		

학습 계획

- 실험 관련 논문 탐색 및 논문 리뷰

<Unsupervised Driver behavior profiling leveraging recurrent neural networks>

학습 내용



목차

- ▶ 요약
- ▶ 서론
- ▶ 리뷰
- ▶ 방법론
- ▶ 실험
- ▶ 결론



요약

- 이전 접근법 단점
 - 실무자가 레이블이 지정된 데이터를 준비해야 함
 - 선형적으로 알려지지 않은 공격적인 행동 분류할 수 없음
- 본 논문에서는 비지도 학습 패러다임을 활용하는 운전자 행동 프로파일링 접근법 제안
 - 운전자 프로파일링 문제를 이상 탐지로 캐스팅함
 - 일련의 특징 벡터가 다음 특징 벡터를 예측하기 위해 반복 신경망을 구축
 - Normal 주행 데이터만으로 모델 훈련
 - 공격자의 운전자 행동은 높은 회귀 오류, 정상적 운전자 행동은 낮은 회귀 오류를 생성
 - 위의 오차가 운전자 행동 프로파일링을 위한 적절한 출력이 될 수 있음을 알고, 정확한 성능을 달성함
- 추가 실험
 - 각 공격적인 운전자 동작을 식별하기 위한 최적의 시퀀스 길이 level 분석



서론

- 이전 연구
 - 자동차에 내장된 텔레매틱스 시스템 또는 CAN(Controller Area Network)과 같은 다양한 센서 사용
 - 요즘 운전자들은 항상 스마트폰을 가지고 다니므로, 모바일 장치에서 추출한 센서 측정값을 활용하고 운전자 행동을 분석하고 Pay-How-You-Drive와 같은 상용화된 산업 응용 프로그램을 여러 연구에서 활용됨[3]



서론

■ 운전자 행동 프로파일링에 대한 초기 접근 방식은 통계 분석으로 시작

- 이전 연구
 - 운전 데이터를 엄밀히 조사하고 공격적인 운전자 행동을 식별하기 위한 특정 휴리스틱 규칙을 알아냄
- 통계적 접근 방식의 현실에서의 제한사항
 - 실무자는 각각의 공격적인 운전자 행동에 대한 탐지 규칙을 설정해야 함
 - 이는 특정 양의 리소스 소비를 유발
 - 운전자 행동 패턴이 변경되면 휴리스틱 규칙을 자주 업데이트해야 함
 - 머신러닝 알고리즘 발달로 위와 같은 한계를 해결
- 학습 기반 운전자 행동 프로파일링 접근 방식의 장애폭
 - 실무자는 특정 양의 리소스를 소비하는 레이블이 지정된 데이터 세트를 준비해야 함
 - 보이지 않는 공격적인 운전자 행동이 발생하면 지도 학습에서 훈련된 모델은 공격적인 운전자 행동으로 분류할 수 없음[3], [12], [17]
 - 정상적인 운전 데이터를 모델에만 제공하면 모델이 훈련된 정상적인 패턴과 구별되는 다른 패턴을 이상으로 식별

서론

■ 모델 훈련 중 정상적인 운전 데이터만 필요한 운전자 행동 프로파일링에 대한 새로운 접근 방식 제안




Fig. 1. The architecture of the proposed driver behavior profiling approach

- log level 운전 데이터에서 일련의 특정 레이블 설정
- 물리적 측정 데이터가 주어진 시점스 직후 특정 패턴을 회귀하도록 모델 훈련
- 여러된 특정 패턴을 실제 특정 레이블 간의 유사 측정
- 오류를 정상적인 운전자 행동에서 공격적인 운전자 행동을 식별하는 적절한 임계값으로 분류
- 오류가 특정 임계값 수준보다 커지면 특정 시스템을 이상(중적)으로 분류

서론

- 비지도 학습 패러다임에서 운전자 행동 프로파일링에 대한 새로운 접근 방식 설계
- 모델이 정상적인 운전 데이터만 훈련되지 않은 한 공격적인 운전자 행동 유형을 효과적으로 식별하는 접근 방식을 분석
- 공격적인 주행 동작에 유형에 따라 시퀀스 길이의 최적 크기가 다양하다는 것을 실험적으로 발견

리뷰

리뷰

■ 통계적 접근 방식

운전 데이터 분석 및 통계 기반 운전 이벤트 분류가 포함됨

- Berndt et al. [2]
자신 변경 및 회전에 대한 운전자의 의도를 추론하기 위한 연구.
HMM(Hidden Markov Models)을 이용한 패턴 매칭을 통해 다가오는 행동이 위험한지 판단하고 피드백을 제공하는 방법을 제안
- Choi et al. [5]
운전 행동 분류, 주의 산만 감지, 운전자 식별의 세 가지 목표로 연구.
HMM을 사용하여 특정 운전 기능을 감지하여 행동을 분류하고 주의 산만을 감지함.
GMM(Gaussian Mixture Model)을 사용하여 드라이버의 특성을 모델링하면서 드라이버를 식별
- Zhang et al. [18]
제한된 시스템 SafeDrive는 비정상 운전 행동을 실시간으로 감지.
운전 데이터의 행동 모델에 대한 상태 그래프를 생성하고 온라인 행동 스트림과 비교 후 유의한 차이가 보이면 비정상적으로 분류
- Eren et al. [7]
운전 행동을 분석하고 연료 소비를 줄이는 방법을 알려주는 방법론을 제안.
선형 모델이 있는 동작 감지 모듈, 연료 소비를 평가하기 위한 피지 모듈, 제안 모듈을 설정

리뷰

■ 통계적 접근 방식

운전 데이터 분석 및 통계 기반 운전 이벤트 분류가 포함됨

- Dai et al. [6]
운전자와 관련된 위험한 운전 감지하는 데 중점을 둠.
그들은 스마트로드 센서를 사용하여 수평 가속도의 데이터 사용.
사전 정의된 음주 운전 패턴은 효율적인 탐지를 위해 수집된 데이터와 여러 차례 매칭을 거침
- 이전 연구는 신뢰할 수 있는 분류 성능을 달성
- 대부분은 미리 정의된 규칙이나 패턴을 사용하는 방식으로 문제를 해결
- 통계적 접근 방식으로만 알 수 없는 유형의 비정상 운전을 감지할 수 없다는 한계 존재

리뷰

■ 지도학습 접근 방식

- Zhang et al. [17]
다양한 양식의 고차원 데이터를 통해 운전 행동 분류를 연구.
데이터 포인트 간의 상관관계를 탐색하여 특징을 모델링한 후 CNN(Convolutional Neural Network)을 사용하여 특징을 추출.
분류 모델은 두 가지 유형의 주의 기반 순환 신경망(RNN)으로 설계
- Amataet al. [1]
운전 스타일과 교통 상황의 두 가지 요인에 따라 예측 모델을 제안.
운전 스타일만 있는 행동 예측을 위해, 인형 피라 모델을 구성.
배터리와 네트워크를 사용하여 두 요인을 모두 고려하여 주어진 상황에서 운전자가 감속할지 예측
- Olaviy et al. [14]
운전 행동을 예측하는 연구.
DBRNN(Deep Bidirectional Recurrent Neural Network)을 사용하는 시스템은 교통 상황과 현재 운전 스타일을 인식하고 앞으로의 운전 행동을 예측
- Wu et al. [16]
정상/비정상 운전 구분하는 것이 아니라 가감, 제동, 회전 등의 운전 행동을 분류하는 학습 모델을 확립.
지문 패턴, 머신(SVM), 로지스틱 회귀 및 K-평균 및 미분(KNN)과 같은 다양한 기계 학습 기술을 사용하여 모델을 훈련하고 시간 창을 기반으로 세그먼트를 분리하는 데이터 처리 프로세스를 거침

리뷰

■ 지도학습 접근 방식

- Chen et al. [4]
운전 행동을 감지 및 Identification 시스템(ID)이라는 시스템을 제안.
제한하는 시스템은 SVM을 사용하여 실시간으로 들어오는 데이터 스트림을 분류
- 이러한 방법들은 통계적 방법의 한계를 뛰어넘어 연구 결과 높은 탐지 성능을 보임
- 이 연구에 사용된 대부분의 데이터는 실험 환경에서 수집되어 label은 정확함
- 실제로는 레이블이 지정되지 않은 데이터에 대한 접근성이 떨어진다는 지도 접근 방식의 한계로 볼 수 있음

리뷰

■ 비지도학습 접근 방식

- 이전 연구에서는 실제 세계에 더 잘 적용하기 위해 레이블이 지정되지 않은 데이터로 운전 행동과 스타일을 식별
- Fugilandoet al. [9]
레이블이 지정되지 않은 데이터를 사용하여 운전 스타일에 따라 여러 운전자를 분류하기 위해 연구.
운전자의 유사성과 관련된 기능을 선택하여 유사한 운전 스타일로 클러스터링.
K-means 클러스터링으로 진행하여 드라이버를 성공적으로 분류했습니다.
- Van Ly et al. [15]
운전 행동을 예측하는 연구.
DBRNN(Deep Bidirectional Recurrent Neural Network)을 사용하는 시스템은 교통 상황과 현재 운전 스타일을 인식하고 앞으로의 운전 행동을 예측
- Mitrovic et al. [13]
운전 스타일 분류 및 운전 행동 예측에 대해 연구.
단기 예측을 위해 10분 분량의 데이터를 사용하여 MLP(다중 퍼셉트론) 모델을 훈련.
K-means 클러스터링을 통한 장기 예측을 제안하였고, 단기 예측보다 운전 행동의 발전이 큰 데이터를 사용
- Mantoukaet al. [11]
비지도학습 접근 방식으로 안전하지 않은 운전 스타일을 별도로 감지하기 위해 연구.
제한하는 방법론은 1단계는 불안정한 운전 감지, 2단계는 불안정한 운전 감지, 3단계는 불안정한 운전 감지

방법론

데이터셋 수집

- [3],[8]에서 공개적으로 배포된 데이터셋 활용
 - 15년 이상 자동차를 운전한 두 명의 숙련된 운전자의 운전 데이터가 포함
 - 스마트폰에 내장된 IMU 센서 측정된 두 명의 운전자가 약 13분 동안 'Honda Civic' 차량으로 경로를 4번 주행하는 동안 설정됨
 - 7가지 유형의 운전자 행동이 포함되어 있음
 - 일반적인 운전자 행동
 - 6가지 공격적 운전자 행동
 - 공격적 브레이크, 공격적 가속, 공격적 좌회전, 공격적 우회전, 공격적 우측 차선 변경, 좌측 공격적 차선 변경
- 수집된 주행 데이터의 특징(feature)
 - 가속도, 선회 가속도, 자력계, 자이로스코프
 - 각 특징의 총 개수는 12개
 - 각 feature는 x,y,z축에 대한 3개의 값을 포함하기 때문

피쳐(feature) 가공

- 데이터 세트를 획득한 후 임시 로그 수준 운전 데이터에서 특징 벡터를 추출
- 원시 운전 데이터를 특징 벡터로 변환하고 각각 모델의 입력 및 출력이 되는 행을 설정하는 것을 목표로 함
- 가능 엔지니어링 프로세스 ; 타임스탬프 보정, 크기 조정 및 윈도우 슬라이딩

피쳐(feature) 가공

- 타임스탬프 보정
 - 가속도, 선회 가속도, 자력계 및 자이로스코프 센서 측정값은 원시 데이터의 다른 주파수로 기록됨
 - 특징 기간 동안 각 특징의 데이터 포인트 수가 다르기에 특징 벡터의 고정된 모양을 만들기 위해서는 주파수 보정
- [8]과 [3]에서 설명한 이전 접근 방식에 따라 목표 주파수를 50Hz로 설정하고 모든 기능의 주파수를 50Hz로 통합
 - 주파수가 50Hz 이상인 특징의 경우 계산을 위해 다중샘플링을 다프감으로 초기 주기의 첫 번째 값을 선택
 - 대표값의 지료가 순환적 행동 학습 패턴에서 의미 있는 차이를 보이지 않음을 실험적으로 확인했음에 유의
- 업샘플링은 Zero-order-hold 방식을 사용하여 대상 주파수보다 낮은 주파수를 가진 특징 데이터의 초기 주기의 첫 번째 값에서 근사값을 추출
- Zero-order-hold는 신호 처리에서 일반적으로 사용되는 방식으로, 주어진 데이터에서 이들 사이의 값에 가까운 상수 값을 복제하여 연속적인 데이터를 생성
 - 기존의 디지털-아날로그 변환기에 의해 수행되는 실제 신호 재구성의 수학적 모델
 - 즉, 하나의 샘플 간격 동안 각 샘플 값을 유지하여 이상 시간 신호를 연속 시간 신호로 변환하는 결과를 설명
- 업샘플링 및 다중샘플링 접근 방식은 목표 주파수(50Hz)에 따라 선택되므로, 고정된 모양의 특징 벡터를 설정할 수 있음

피쳐(feature) 가공

- 크기
 - 주파수 차이의 장래를 해결한 후에는 특징 간의 스케일 차이를 관리해야 함.
 - 모델 훈련을 방해하기 위해 각 기능의 다른 스케일을 예상했기 때문에 MinMax 스케일링을 적용하여 이 차이를 완화
 - Eq.10에 설명된 정의에 따라 MinMax 스케일링을 설정했습니다.
 - 모델 훈련 중에 정상적인 운전 데이터만 사용하기 때문에

$$X_{scaling} = \frac{X_i - X_{min}}{X_{max} - X_{min}}, \quad (1)$$

피쳐(feature) 가공

- 윈도우 슬라이딩
 - 특정 창 크기를 설정하고 타임스탬프와 함께 슬라이딩하여 구성된 데이터 창을 생성
 - 창: 각각 모델에 대한 입력이 되고 모델의 예측을 위한 응답이 됨
 - 윈도우 크기를 25로 설정했습니다 고정
 - 12개의 특징 유형의 존재하므로 특징 벡터 시퀀스(입력)의 모양은 (25, 12), ground truth 값의 모양은 (1, 25)가 됨
 - 특징 벡터 시퀀스와 대상 ground truth로 구성된 데이터 세트를 설정
 - 창 크기가 25, 50, 100 및 200인 창 슬라이딩을 처리하고 이후 역선에서 드라이버 동작 프로파일링 성능을 분석

Unsupervised Driver Behavior Profiling Involving Recurrent Neural Networks




Fig. 3. Pairs of data consists of the feature vector sequence and the ground-truth feature vector

훈련단계

- 정상 주행 데이터의 고유한 특성을 학습하도록 모델 훈련
 - 선행 연구[17]와 같이 주행 데이터가 특정 공간에서 시간적 역학을 가진 것으로 예상
 - 주행 시계열 패턴을 효과적으로 분석하기 위해 반복적인 형태의 신경망을 사용
 - LSTM(Long Short Term Memory) 신경망을 모델로 활용
 - 목표 값을 회귀하기 위해 LSTM 계층을 구현하고 순환 계층 끝에 완전 연결 계층을 추가함
 - 특징 벡터를 입력으로 시퀀스화도독 모델을 설계하고 주어진 입력 시퀀스 직후에 기록된 특징 벡터를 예측
 - MSE(Mean Squared Error) 손실 함수를 사용하여 예측된 특징 벡터와 정답 사이의 차이를 최소화하도록 목표 설정
- 과적합의 위험을 피하기 위해 L1 및 L2 정규화를 사용하고 Adam 모델로 최적화 함

주론단계

- 주어진 일련의 특징 벡터가 공격적인 운전자 행동을 나타내는지, 정상적인 운전자 행동을 나타내는지 분류
- 주어진 특징 벡터 시퀀스가 정상적 주행을 나타낸다고 가정
 - 정상적인 운전자 행동 패턴이 훈련 단계에서 이미 훈련되었기에 추론 단계에서의 회귀 손실은 작을 것임
 - 반면, 주어진 시퀀스가 공격적인 운전자 행동을 의미할 때 회귀 손실이 커질 것임
- 공격적인 운전자 행동의 특성은 선형적으로 훈련되지 않기에 모델은 공격적 운전자 행동의 대상 특징 벡터를 정확하게 회귀할 수 없음
- 검증 시퀀스를 훈련된 모델에 제공하고 예측과 목표 값 사이의 손실을 계산하고 손실이 특정 임계값 수준보다 클 경우 공격적인 드라이버 동작으로 시퀀스를 분류
 - 임계값 수준이 분류 성능에 영향을 미칠 수 있음



실험설정

- 훈련단계
 - 특징 수의 정상 운전 데이터를 샘플링
- 추론단계
 - 일반 주행 데이터와 6가지 유형의 주행 데이터 세트를 모두 활용하여 이전 분류 수행
 - 6가지 유형 : 공격적 우회전, 좌회전, 우회전 차선 변경, 좌회전 차선 변경, 제동 및 가속
- 성능검증
 - ROC-AUC(Receiver Operating Characteristic - Area Under Curve) 사용
- 실험 목표
 - 제안된 접근 방식의 성능은 임계값 수준에 따라 달라지므로 수많은 임계값에서 전반적인 효율성을 측정하는 것

실험결과

제언하는 정상적인 운전 패턴으로부터 훈련된 모델은 공격적인 운전 패턴을 성공적으로 감지할 수 있음을 보여주고, label이 지정된 각 이벤트에 대해 높은 성능을 보이는 창 크기별 테스트

Table 1. Experiment result on our approach. Our approach precisely achieved driver behavior profiling performance in general but failed to identify aggressive acceleration.

		window				Avg. of AUC
		200	100	50	25	
Label	Aggressive Right Turn	0.9648	0.9722	0.9725	0.9647	0.9686
	Aggressive Left Turn	0.913	0.9409	0.9421	0.9202	0.9311
	Aggressive Right Lane Change	0.9028	0.8872	0.8979	0.8691	0.8892
	Aggressive Left Lane Change	0.8962	0.8855	0.9026	0.8747	0.8907
	Aggressive Brake	0.9057	0.8889	0.8954	0.8936	0.8959
	Aggressive Acceleration	0.7326	0.7012	0.6769	0.7241	0.7087
	Average of AUC by window	0.8872	0.8793	0.8812	0.8744	
Average of AUC						0.8805

실험결과

Table 1. Experiment result on our approach. Our approach precisely achieved driver behavior profiling performance in general but failed to identify aggressive acceleration.

	window				Avg of AUC by label
	200	100	50	25	
Label	Aggressive Right Turn	0.9648	0.9722	0.9725	0.9686
	Aggressive Left Turn	0.9213	0.9409	0.9421	0.9202
	Aggressive Right Lane Change	0.9028	0.8872	0.8979	0.8691
	Aggressive Left Lane Change	0.8962	0.8855	0.9026	0.8747
	Aggressive Brake	0.9057	0.8889	0.8954	0.8936
	Aggressive Acceleration	0.7326	0.7012	0.6769	0.7211
Average of AUC by window					0.8872
Average of AUC					0.8805

공격적인 가속은 일반 운전자와 구분하기 어렵기 때문

실험결과

■ Label의 경우, IMU 센서로 측정한 관성 값을 특징으로 사용

- 운전자가 우회전, 좌회전, 브레이크 및 자전 변경 시 중요한 값 변화를 감지하는 데 유용함
- 즉, 공격적인 운전 패턴을 감지하는 데 민감함



결론

■ 본 논문은 비지도 학습 패러다임에서 반복 신경망을 활용하여 운전자 행동 프로파일링에 대한 새로운 접근 방식을 제안함

- 원시 로그 수준 스마트폰 센서 측정에서 고정된 모양(fixed-shape) 특징 벡터를 추출함
- 일련의 특징 벡터가 주어지면 다음 특징 벡터를 예측하는 LSTM regressor를 설계함
- 정상적인 운전자 행동의 시계열 특성을 학습하기 위해서만 정상적인 운전 데이터로 모델을 훈련
- 공격적인 운전자 행동에서 파생된 일련의 특징 벡터가 주어지면 훈련된 모델이 높은 회귀 오류를 초래함을 알아냄
- 반면에, 일반 시퀀스에서 낮은 회귀 오류를 제공함
- 회귀 오류를 임계값으로 지정함으로써 제안한 방식은 공격적인 운전자 행동을 정상적인 행동과 효과적으로 분류할 수 있음을 보임

■ 향후 연구

- 다양한 운전자, 다른 유형의 자동차, 다른 경로 및 여러 유형의 스마트폰을 사용하여 접근 방식에 대한 추가 외부 검증을 수행할 것

참고문헌

1. Amata, H., Miyajima, C., Nishino, T., Kitaoka, N., Takeda, K.: Prediction model of driving behavior based on traffic conditions and driver types. In: 2009 12th International IEEE Conference on Intelligent Transportation Systems. pp. 1-6. IEEE (2009)
2. Berni, H., Dietmayer, K.: Driver intention inference with vehicle onboard sensors. In: 2009 IEEE International conference on vehicular electronics and safety (ICVES). pp. 102-107. IEEE (2009)
3. Carvalho, E., Ferreira, B.V., Ferreira, J., De Souza, C., Carvalho, H.V., Suhara, Y., Pentland, A.S., Pessin, G.: Exploiting the use of recurrent neural networks for driver behavior profiling. In: 2017 International Joint Conference on Neural Networks (IJCNN). pp. 3016-3021. IEEE (2017)
4. Chen, Z., Yu, J., Zhu, Y., Chen, Y., Li, M.: D-3: Abnormal driving behaviors detection and identification using smartphone sensors. In: 2015 12th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON). pp. 524-532. IEEE (2015)
5. Choi, S., Kim, J., Kwak, D., Angkittarakul, P., Hansen, J.: Analysis and classification of driver behavior using in-vehicle can-bus information. In: Biennial workshop on DSP for in-vehicle and mobile systems. pp. 17-19 (2007)
6. Dai, J., Teng, J., Bai, X., Shen, Z., Xuan, D.: Mobile phone based drunk-driving detection. In: 2010 4th International Conference on Pervasive Computing Technologies for Healthcare. pp. 1-8. IEEE (2010)
7. Eren, H., Makinaja, S., Akın, E., Vilmaz, A.: Estimating driving behavior by a smartphone. In: 2012 IEEE Intelligent Vehicles Symposium. pp. 234-239. IEEE (2012)
8. Ferreira, J., Carvalho, E., Ferreira, B.V., de Souza, C., Suhara, Y., Pentland, A., Pessin, G.: Driver behavior profiling: An investigation with different smartphone sensors and machine learning. PLoS one 12(4), e0174959 (2017)
9. Fugliandolo, U., Massaro, E., Santi, P., Milardo, S., Abida, K., Stahlmann, R., Netter, F., Ratti, C.: Driving behavior analysis through can-bus data in an uncontrolled environment. IEEE Transactions on Intelligent Transportation Systems 20(2), 737-748 (2018)
10. Hu, J., Xu, L., He, X., Meng, W.: Abnormal driving detection based on normalized driving behavior. IEEE Transactions on Vehicular Technology 66(8), 6645-6652 (2017)
11. Mantouka, E.G., Bampourakis, E.N., Vlahogiannis, E.I.: Identifying driving safety profiles from smartphone data using unsupervised learning. Safety Science 119, 84-90 (2019)

결론

참고문헌

참고문헌

12. Martínez, M., Echanobe, J., del Campo, I.: Driver identification and impostor detection based on driving behavior signals. In: 2016 IEEE 19th International Conference on Intelligent Transportation Systems (ITSC). pp. 372-378. IEEE (2016)
13. Mitrovic, D.: Machine learning for car navigation. In: International Conference on Industrial, Engineering and Other Applications of Applied Intelligent Systems. pp. 670-675. Springer (2001)
14. Olabiyi, O., Martinson, E., Chintalapudi, V., Guo, R.: Driver action prediction using deep (bidirectional) recurrent neural network. arXiv preprint arXiv:1706.02257 (2017)
15. Van Ly, M., Martin, S., Trivedi, M.M.: Driver classification and driving style recognition using inertial sensors. In: 2013 IEEE Intelligent Vehicles Symposium (IV). pp. 1040-1045. IEEE (2013)
16. Wu, M., Zhang, S., Dong, Y.: A novel model-based driving behavior recognition system using motion sensors. Sensors 16(10), 1746 (2016)
17. Zhang, J., Wu, Z., Li, F., Xie, C., Ren, T., Chen, J., Liu, L.: A deep learning framework for driving behavior identification on in-vehicle can-bus sensor data. Sensors 19(6), 1356 (2019)
18. Zhang, M., Chen, C., Wo, T., Xie, T., Bhuiyan, M.Z.A., Lin, X.: SafeDrive: online driving anomaly detection from large-scale vehicle data. IEEE Transactions on Industrial Informatics 13(4), 2087-2096 (2017)